



پیش بینی قیمت دارایی با فرآیند براونی کسری و مدل واسیچک مبتنی بر الگوریتم ژنتیک

علی خانی^(۱) و اسکندر بشم^(۲) و داوود احمدیان^(۳)

^(۱) گروه ریاضی، دانشکده علوم پایه، دانشگاه شهید مدنی آذربایجان، تبریز، ایران

^(۲) گروه ریاضی، دانشکده علوم پایه، دانشگاه شهید مدنی آذربایجان، تبریز، ایران

^(۳) گروه ریاضی کاربردی، دانشکده ریاضیات، آمار و علوم کامپیوتر، دانشگاه تبریز، تبریز، ایران

دبیر مسئول: منصور سراج

تاریخ پذیرش: ۱۴۰۵/۰۳/۱۹

تاریخ دریافت: ۱۴۰۴/۰۴/۲۳

چکیده: مدل سازی دقیق مسیر قیمت دارایی ها در بازارهای مالی پرتلاطم، به ویژه رمزارزها، همواره با چالش هایی مانند وابستگی زمانی پیچیده و رفتار غیرخطی روبه رو است. مدل های کلاسیک همچون حرکت براونی در شبیه سازی ویژگی حافظه داری و بازگشت به میانگین قیمت با محدودیت روبه رو هستند. در این پژوهش، با ترکیب فرآیند براونی کسری و مدل واسیچک و به کارگیری الگوریتم ژنتیک در بهینه سازی وزن های ترکیبی، چارچوبی نوین برای شبیه سازی مسیر قیمت دارایی ارائه شده است. در این روش، مدل های یادشده به طور جداگانه و بر اساس داده های تاریخی پیاده سازی شده اند و نتایج آن ها با ضرایب وزنی بهینه، ترکیب شده است. سپس با تعریف تابع هدف مبتنی بر کمینه سازی خطای پیش بینی، وزن های بهینه با استفاده از الگوریتم ژنتیک محاسبه شده است. یافته ها بر مبنای داده های بیت کوین نشان می دهد مدل ترکیبی پیشنهادی دقت بیشتری نسبت به مدل های منفرد دارد و عملکرد قابل قبولی در پیش بینی نوسان های قیمت ارائه می کند. این چارچوب می تواند به عنوان ابزاری کارآمد در تصمیم گیری مالی، مدیریت ریسک و طراحی راهبردهای سرمایه گذاری در بازارهای پرتلاطم استفاده شود.

واژه های کلیدی: فرآیند براونی کسری، مدل واسیچک، الگوریتم ژنتیک، بهینه سازی مسیر قیمت دارایی.

رده بندی ریاضی: 62P05, 60G22, 68W50

۱ مقدمه

پیش بینی قیمت و بازده سهام یکی از مسائل اساسی حوزه مالی است که در دهه های اخیر توجه بسیاری را به خود جلب کرده است. در این راستا، مدل های آماری کلاسیک و روش های نوین مبتنی بر هوش مصنوعی و یادگیری ماشین به عنوان ابزارهای مؤثر در تحلیل و پیش بینی سری های زمانی مالی شناخته می شوند. شواهد تجربی نشان می دهد مدل های غیرخطی یادگیری ماشین معمولاً در پیش بینی بازده سهام، عملکرد دقیق تری نسبت به مدل های خطی دارند. مطالعات تجربی در ایران نیز این موضوع را تأیید می کند؛ برای نمونه، جعفری و همکاران [۱] با تحلیل داده های بورس اوراق بهادار تهران نشان داده اند که مدل های غیرخطی یادگیری ماشین موفق تر عمل می کنند.

^۱ نویسنده مسئول مقاله

(A. Khani) Khani@azaruniv.ac.ir

در سطح بین المللی نیز تحقیقات متعددی به کارایی مدل های تصادفی و الگوریتم های تکاملی در مدل سازی پویای قیمت دارایی ها پرداخته اند. برای مثال، آفوماتا و همکاران [۳] با بهره گیری از معادلات دیفرانسیل تصادفی، تغییرات و واریانس قیمت سهام در بورس نیجریه را بررسی کردند. همچنین، نادر جان و همکارش مدل میانگین متحرک یکپارچه خودرگرسیون^۲ را با مدل های حرکت براونی هندسی^۳ و واسیچک^۴ برای پیش بینی قیمت سهام در بورس مالزی مقایسه کردند و نشان دادند مدل آریما در افق های زمانی کوتاه مدت عملکرد بهتری دارد [۱۶]. در تحقیق دیگری، لوونتایس و همکاران [۱۴] با استفاده از مدل حرکت براونی کسری^۵ نشان دادند مدل های سنتی قادر به شبیه سازی همه جنبه های رفتاری بازار - به ویژه حافظه داری و روابط غیرخطی - نیستند. همچنین، هو و همکاران [۸] با مقایسه مدل آریما، شبکه های عصبی و مدل حافظه بلندمدت کوتاه مدت^۶ بر کارایی بالای مدل های یادگیری عمیق و به ویژه LSTM حتی در شرایط پرنوسان بازار تأکید کردند.

با توجه به چالش هایی مانند وجود حافظه داری، رفتار غیرخطی و ساختار پیچیده در سری های زمانی مالی، استفاده از مدل های ترکیبی نوین می تواند دقت پیش بینی را افزایش دهد. پژوهش ها نشان می دهد فرآیند براونی کسری به دلیل ساختار حافظه دار و مدل واسیچک به سبب خاصیت بازگشت به میانگین، هر یک قابلیت های ویژه ای برای مدل سازی قیمت دارایی دارند. ترکیب این دو مدل همراه با بهینه سازی به کمک الگوریتم ژنتیک می تواند عملکرد بهتری در مقایسه با حالت های منفرد ارائه کند [۱۸، ۱۹].

هدف اصلی این پژوهش، بهبود دقت پیش بینی قیمت دارایی ها از طریق توسعه ی مدلی ترکیبی است که رفتار دینامیک بازار را به صورت کمی و کیفی بازنمایی کند. در این رویکرد، فرآیند براونی کسری برای شناسایی وابستگی های بلندمدت و روندهای پیوسته ی قیمت و مدل واسیچک برای لحاظ کردن خاصیت بازگشت به میانگین و نوسانات کوتاه مدت، در قالب یک چارچوب ترکیبی به کار گرفته شده اند. به عبارت دیگر، مدل واسیچک به طور مستقل برای پیش بینی قیمت استفاده نشده است، بلکه به عنوان یک مسیر شبیه سازی مکمل در ترکیب با فرآیند براونی کسری و با وزن دهی بهینه توسط الگوریتم ژنتیک، در شکل گیری مسیر پیش بینی نهایی نقش دارد. این چارچوب امکان تحلیل سهم هر مولفه در رفتار قیمت و تبیین منابع اصلی نوسانات بازار را فراهم می کند و در عین حال، پیش بینی دقیق تری ارائه می دهد.

در سال های اخیر، بخش قابل توجهی از پژوهش ها در حوزه پیش بینی بازار، بر مدل های ترکیبی مبتنی بر یادگیری ماشین تمرکز داشته اند. برای مثال، در پژوهش باقرپور و همکاران [۳] از ترکیب XGBoost^۷ و الگوریتم ژنتیک برای بهبود دقت پیش بینی جهت شاخص کل استفاده شده است؛ همچنین، رحیمی و همکاران [۲] با بهره گیری از مدل ARMA-GARCH^۸ و شبکه عصبی کانولوشنی، شوک های بازار سهام را پیش بینی کرده اند. طلایی و همکاران [۴] نیز مدلی ترکیبی بر پایه زنجیره مارکوف مخفی و شبکه عصبی برای پیش بینی شاخص بورس تهران توسعه داده اند. وجه مشترک این مطالعات، تکیه بر الگوریتم های یادگیری ماشین و شبکه های یادگیری عمیق است.

علاوه بر این مطالعات، پژوهش های بسیار به روز نیز به کاربرد مدل های هیبریدی در پیش بینی رمزارزها پرداخته اند. مهدی و همکاران (۲۰۲۵) یک مدل هیبریدی ترکیبی از مدل های مبتنی بر مکانیزم توجه و واحد بازگشتی دروازه ای ارائه کرده اند که توانایی مدل مبتنی بر مکانیزم توجه در شناسایی الگوهای بلندمدت و توانایی واحد بازگشتی دروازه ای در مدلسازی روندهای کوتاه مدت و توالی زمانی را با هم ادغام می کند. این مدل برای پیش بینی قیمت روزانه بیت کوین و اتریوم با استفاده از داده های تاریخی قیمت، حجم معاملات و شاخص ترس و طمع به کار گرفته شده و در مقایسه با سایر مدل های شبکه عصبی و شبکه های بازگشتی دوطرفه عملکرد بهتری نشان داده است [۹]. همچنین، ناگولا و آکساکیس (۲۰۲۲) مدلی هیبریدی ترکیبی از مدل های طبقه بندی و رگرسیون با الگوریتم شبکه های متقاطع عمیق ارائه کرده اند که تعامل خودکار بیش از ۱۰۰ شاخص فنی و متغیرهای کنترلی از جمله توان محاسباتی شبکه بیت کوین و بازده شاخص S&P ۵۰۰ را مدلسازی می کند. نتایج این مطالعه نشان داده است که مدل پیشنهادی در پیش بینی بازده لگاریتمی بیت کوین دقت بالایی دارد و استراتژی های معاملاتی سودآور و کم ریسک ارائه می دهد [۱۰]. این مطالعات اخیر نشان می دهند که مدل های هیبریدی می توانند دقت پیش بینی را در بازارهای پرنوسان رمزارزها به طور قابل توجهی افزایش دهند و جایگاه پژوهش حاضر را در ادبیات مرتبط تقویت کنند.

برخلاف این رویکردها، نوآوری پژوهش حاضر در تمرکز بر مدل های تصادفی مبتنی بر رفتار درونی بازار و تلفیق فرآیند براونی کسری (برای مدل سازی حافظه داری بلندمدت) و مدل واسیچک (برای بازگشت به میانگین) است. همچنین، به جای بهینه سازی ساختار مدل های یادگیری ماشین، در این پژوهش پارامترهای مدل های تصادفی با استفاده از الگوریتم ژنتیک به صورت هم زمان تنظیم شده اند تا مسیر قیمتی دارایی با واقعیت بازار سازگار شود. بنابراین، چارچوب پیشنهادی از نظر نوع مدل، هدف بهینه سازی و مبانی تئوریک با مطالعات پیشین اختلاف ساختاری و مفهومی دارد و رویکردی مکمل در ادبیات پیش بینی مالی ارائه می دهد.

بر همین اساس، هدف این پژوهش ارائه چارچوبی نوآورانه مبتنی بر ترکیب فرآیند براونی کسری و مدل واسیچک با بهره گیری از الگوریتم ژنتیک به عنوان ابزار بهینه سازی است. ساختار مدل پیشنهادی به گونه ای طراحی شده است که به طور هم زمان از خواص حافظه داری و بازگشت

^۲Autoregressive Integrated Moving Average, ARIMA

^۳Geometric Brownian Motion

^۴Vasicek model

^۵Fractional Brownian Motion, fBm

^۶Long Short-Term Memory, LSTM

^۷eXtreme Gradient Boosting

^۸Autoregressive Moving Average-Generalized Autoregressive Conditional Heteroskedasticity

به میانگین بهره‌برداری شود و ضرایب مدل در فضای پارامتری بهینه گردد. در بخش تجربی، مسیرهای قیمتی دارایی‌های منتخب (از جمله رمزارز بیت‌کوین) شبیه‌سازی و عملکرد مدل پیشنهادی با دیگر روش‌های رایج مقایسه خواهد شد. نتایج این پژوهش می‌تواند دقت پیش‌بینی را افزایش دهد، مدیریت ریسک را بهبود بخشد و تصمیم‌گیری سرمایه‌گذاران را در بازارهای مالی پرتلاطم تقویت کند.

۲ مبانی نظری

مدل‌سازی و پیش‌بینی قیمت دارایی‌ها در بازارهای مالی از موضوعات اساسی تحلیل مالی است. نوسان‌های پیچیده و پویای قیمت دارایی‌ها که عمدتاً ناشی از ماهیت غیرقابل پیش‌بینی و تصادفی بازارهای مالی است، بهره‌گیری از مدل‌های پیشرفته ریاضی و آماری را برای شبیه‌سازی و پیش‌بینی دقیق رفتار بازار ضروری می‌کند. در سال‌های اخیر، دو رویکرد اصلی در این حوزه مورد توجه قرار گرفته است: مدل‌های آماری سنتی و مدل‌های مبتنی بر یادگیری ماشین.

در میان مدل‌های آماری، خانواده مدل‌های میانگین متحرک یکپارچه خودرگرسیون برای مدل‌سازی روند سری‌های زمانی و مدل‌های گارچ برای مدل‌سازی نوسان استفاده می‌شود. این مدل‌ها بر فرض خطی بودن روابط، ایستایی داده‌ها و توزیع نرمال باقی‌مانده‌ها استوار است. با این حال، در بسیاری از بازارهای مالی، به‌ویژه بازارهای نوظهور و پرنوسان مانند دارایی‌های دیجیتال، این مفروضات اغلب نقض می‌شود و رفتار بازار به‌شکل غیرخطی و همراه با نوسان‌های شدید پدیدار می‌شود. یکی از مهم‌ترین چالش‌های مدل‌های آماری سنتی، ناتوانی در شناسایی و پیش‌بینی رفتار غیرخطی و شوک ناگهانی است.

در واکنش به این محدودیت، مدل‌های پیشرفته‌تری مطرح شده است. به‌طور خاص، مدل گارچ که توسط بولرسلو ارائه شده است، با لحاظ نوسان شرطی در سری زمانی، گام مؤثری در پیش‌بینی نوسان بازار مالی برداشته است. با این وجود، نسخه کلاسیک این مدل نیز در برابر رفتار غیرعادی بازار و شوک شدید، کاهش کارایی دارد و توان کافی برای مدل‌سازی الگوی پیچیده نشان نمی‌دهد [۵].

همچنین، مدل حرکت براونی اگرچه در مدل‌سازی مسیر قیمت دارایی‌ها کاربرد گسترده دارد، اما در توصیف وابستگی بلندمدت، نوسان چرخه‌ای و ساختار حافظه‌دار بازار محدودیت دارد. برای غلبه بر این کاستی، فرآیند براونی کسری به‌عنوان جایگزین مناسب مطرح شده است که با ویژگی‌هایی چون خودهمبستگی و حافظه بلندمدت، عملکرد بهتری در مدل‌سازی نوسان بازار مالی ارائه می‌دهد [۱۵].

مدل واسپچک که در ابتدا برای مدل‌سازی نرخ بهره پیشنهاد شده بود نیز می‌تواند مکمل فرآیند براونی کسری در توصیف پویایی نرخ بازدهی باشد. ترکیب این مدل‌ها در ساختاری ترکیبی - به‌ویژه زمانی که پارامترهای مدل با استفاده از الگوریتم‌های فراابتکاری همچون الگوریتم ژنتیک بهینه‌سازی شود - می‌تواند دقت شبیه‌سازی مسیر قیمت دارایی را افزایش دهد. الگوریتم ژنتیک نیز با جست‌وجوی بهینه در فضای پیچیده و غیرخطی، از مزیت‌هایی مانند اجتناب از کمینه محلی و بهینه‌سازی هم‌زمان چند پارامتر برخوردار است. استفاده از این روش در مدل‌سازی تصادفی، با کاهش خطای میانگین مربعات بین مسیرهای شبیه‌سازی‌شده و داده‌های واقعی، دقت پیش‌بینی را به‌ویژه در دارایی‌های پرنوسان مانند بیت‌کوین افزایش می‌دهد.

در حوزه پیش‌بینی بازده دارایی نیز، رویکرد مبتنی بر یادگیری ماشین به‌طور گسترده بررسی شده است. پژوهش‌هایی مانند مطالعه خالوزاده و همکاران (۱۳۸۲) نشان می‌دهد مدل خطی توان کافی برای توصیف رفتار پیچیده و پویا در بازار مالی را ندارد و حتی مدل غیرخطی مانند شبکه عصبی نیز به‌تنهایی دقت کامل ندارد. بنابراین، استفاده از ساختار ترکیبی یا هیبرید می‌تواند عملکرد بالاتری در پیش‌بینی بازده دارایی ایجاد کند.

در مجموع، با توجه به ماهیت نوسانی و غیرخطی بازارهای مالی، به‌ویژه در حوزه دارایی‌های دیجیتال، توسعه مدل‌هایی با دقت بالا و توانایی انطباق با واقعیت‌های پیچیده بازار، یک ضرورت علمی است. ترکیب مدل آماری، مدل تصادفی و الگوریتم بهینه‌سازی هوشمند مانند الگوریتم ژنتیک می‌تواند زمینه‌ساز ارائه ابزار تحلیلی قوی‌تر و بهبود تصمیم‌گیری تحلیل‌گران و سرمایه‌گذاران در بازار پویا باشد.

۳ روش‌شناسی تحقیق

در این تحقیق، برای مدل‌سازی و پیش‌بینی مسیر قیمت دارایی‌ها، از رویکرد ترکیبی فرآیند براونی کسری و مدل واسپچک استفاده شده است تا ویژگی‌های حافظه بلندمدت، نوسان‌های پیچیده و رفتار بازگشت به میانگین در داده‌های بازار مالی با دقت بیشتری شبیه‌سازی شود. به‌منظور بهینه‌سازی وزن‌های ترکیبی این مدل‌ها و کاهش خطای پیش‌بینی نسبت به داده‌های واقعی، الگوریتم ژنتیک به‌عنوان ابزار هوشمند جست‌وجو و بهینه‌سازی به‌کار رفته است.

الگوریتم ژنتیک^۹ به دلیل توانایی آن در بهینه سازی مسائل غیرخطی و چندپارامتری انتخاب شده است. تابع هدف مدل ترکیبی پیچیده و دارای چند نقطه بیشینه و کمینه است و روش های مبتنی بر گرادین معمولاً در یکی از این نقاط محلی گیر می کنند، در حالی که GA با جستجوی سراسری و عملگرهای انتخاب، جهش و ترکیب، قابلیت یافتن بهینه های سراسری را دارد. مطالعات متعددی کارایی GA را در مدل سازی داده های مالی تأیید کرده اند.

در این چارچوب، مجموعه داده های تاریخی قیمت دارایی منتخب از منابع معتبر گردآوری و پیش پردازش شده است. سپس، مدل های فرآیند براونی کسری و واسپچک به طور جداگانه پیاده سازی و شبیه سازی شده اند؛ خروجی هر مدل با ضرایب ترکیبی وزن دهی می شود و تابع هدف بر مبنای کمینه سازی خطای میانگین مربعات تعریف شده است.

در نهایت، الگوریتم ژنتیک با جستجوی فضای وزن ها و به روزرسانی جمعیت، ترکیب بهینه را تعیین می کند تا دقت شبیه سازی مدل نسبت به سری زمانی واقعی به بیشینه برسد. این رویکرد، زمینه لازم را برای تحلیل دقیق تر رفتار بازار و بهبود پیش بینی نوسان قیمت فراهم می کند.

با وجود انتخاب الگوریتم ژنتیک، (GA) این الگوریتم به دلیل توانایی جستجوی سراسری، عدم وابستگی به مشتق تابع هدف و سازگاری با مسائل چندپارامتری نسبت به سایر الگوریتم های متاهوریستیک مانند بهینه سازی ازدحام ذرات^{۱۰} و بهینه سازی تکاملی تفاضلی^{۱۱} برتری داشته و در بهینه سازی وزن های ترکیبی مدل های تصادفی عملکرد مناسبی ارائه می دهد. علاوه بر این، به منظور راستی آزمایی و مقایسه عملکرد، مسیرهای شبیه سازی شده حاصل از فرآیند براونی کسری و مدل واسپچک با دو رویکرد دیگر نیز ترکیب شده اند. در رویکرد نخست، الگوریتم PSO برای یافتن ترکیب بهینه مورد استفاده قرار گرفته و به عنوان یک رقیب معتبر برای GA به کار رفته است. در رویکرد دوم، ترکیب غیرخطی با شبکه عصبی چندلایه^{۱۲} به منظور مدل سازی روابط پیچیده و غیرخطی بین مسیرها به کار گرفته شده است. نتایج نشان می دهند که GA در بهینه سازی پارامترهای مدل اصلی مؤثر بوده و PSO و MLP می توانند به عنوان ابزارهای مکمل برای مقایسه، تحلیل حساسیت و راستی آزمایی عملکرد مدل ترکیبی مورد استفاده قرار گیرند.

۳-۱ مدل واسپچک

مدل واسپچک یکی از فرآیندهای تصادفی بازگشت به میانگین است که در مدل سازی سری های زمانی مالی مورد استفاده قرار می گیرد. در این پژوهش، این مدل به منظور پیش بینی مستقیم قیمت دارایی به کار گرفته نشده است، بلکه برای تولید مسیرهای شبیه سازی شده مکمل مبتنی بر داده های تاریخی استفاده شده است. به این منظور، پارامترهای مدل واسپچک بر روی سری زمانی قیمت واقعی دارایی تخمین زده شده و از مسیرهای شبیه سازی شده حاصل، در چارچوب یک مدل ترکیبی استفاده شده است [۱۹].

مدل واسپچک به صورت زیر تعریف می شود:

$$dr_t = \kappa(\bar{r} - r_t) dt + \sigma dW_t, \quad (۱.۳)$$

که در آن r_t متغیر حالت در زمان t ، κ سرعت بازگشت به میانگین، $\bar{r}$ سطح میانگین بلندمدت، σ شدت نوسان و W_t فرآیند وینر استاندارد است. در این مطالعه، ضرایب κ ، $\bar{r}$ و σ با استفاده از روش برآورد درست نمایی بیشینه و مبتنی بر داده های تاریخی قیمت دارایی تخمین زده شده اند [۲۲]. مسیرهای شبیه سازی شده حاصل از این مدل، در ترکیب با مسیرهای فرآیند براونی کسری و با استفاده از الگوریتم ژنتیک وزن دهی شده اند تا مسیر پیش بینی نهایی شکل گیرد.

تابع چگالی احتمال مدل واسپچک برای مشاهدات متوالی با فاصله زمانی Δt به صورت زیر ارائه شده است [۲۰]:

$$f(r_i | r_{i-1}; \theta) = \frac{1}{\sqrt{2\pi \frac{\sigma^2}{\kappa} (1 - e^{-2\kappa \Delta t})}} \exp \left\{ - \frac{[r_i - r_{i-1} e^{-\kappa \Delta t} - \bar{r} (1 - e^{-\kappa \Delta t})]^2}{2 \frac{\sigma^2}{\kappa} (1 - e^{-2\kappa \Delta t})} \right\}, \quad (۲.۳)$$

که در آن $\theta = (\kappa, \bar{r}, \sigma)$ بردار پارامترهای مدل است.

تابع درست نمایی کل بر اساس مشاهدات $r_1, \dots, r_n$ به صورت زیر تعریف می شود:

$$L(\theta; r_1, \dots, r_n) = \prod_{i=2}^n f(r_i | r_{i-1}; \theta), \quad (۳.۳)$$

^۹Genetic Algorithm (GA)

^{۱۰}Particle Swarm Optimization (PSO)

^{۱۱}Differential Evolution (DE)

^{۱۲}Multilayer Perceptron (MLP)

و لاگ-درست‌نمایی:

$$\log L(\theta; r_1, \dots, r_n) = \sum_{i=2}^n \log f(r_i | r_{i-1}; \theta). \quad (4.3)$$

با بیشینه‌سازی این تابع نسبت به پارامترها، ضرایب بهینه مدل $\theta = (\kappa, \bar{r}, \sigma)$ به دست می‌آیند [۱۹].

۳-۲ مدل حرکت براونی کسری

فرآیند براونی کسری برای مدل‌سازی سری‌های زمانی دارای حافظه بلندمدت و خودهمبستگی معرفی شده است. این فرآیند، برخلاف حرکت براونی معمولی، می‌تواند وابستگی‌های بلندمدت و رفتارهای تکرارشونده یا متناوب را که در داده‌های مالی مشاهده می‌شود، به خوبی مدل کند. مقدار شاخص هرست در این مدل، نوع و شدت این وابستگی زمانی را کنترل می‌کند و الگوهای پیچیده‌تر نوسانات بازار را با دقت بیشتری شبیه‌سازی می‌کند. امروزه حرکت براونی کسری به دلیل انعطاف‌پذیری و ساختار ریاضی قدرتمند، به‌طور گسترده در مدل‌سازی مالی، اقتصادسنجی و نظریه سیگنال به کار می‌رود.

تعریف ۳-۲-۱. فرآیند حرکت براونی کسری یک فرآیند تصادفی با حافظه بلندمدت و خودهمبستگی است که به صورت زیر تعریف می‌شود:

$$dX_t = b(X_t, t) dt + B(X_t, t) dB_H(t), \quad (5.3)$$

که در آن $B_H(t)$ فرآیند براونی کسری با شاخص هرست H است و $b(X_t, t)$ و $B(X_t, t)$ به ترتیب تابع رانش و تابع انتشار مدل هستند [۱۵].

برای تخمین پارامترهای حرکت براونی کسری، به‌ویژه نمای هرست H ، از روش برآورد درست‌نمایی بیشینه استفاده می‌شود. چگالی احتمال مربوط به تصادفیات حرکت براونی کسری دارای ساختاری وابسته به تابع کوواریانس است و تابع درست‌نمایی آن به صورت زیر بیان می‌شود:

$$L(H; X) = \frac{1}{\sqrt{(2\pi)^2 |\Sigma_H|}} \exp \left(-\frac{1}{2} X^T \Sigma_H^{-1} X \right), \quad (6.3)$$

که Σ_H ماتریس کوواریانس بر مبنای پارامتر هرست و X بردار مشاهده‌ها (مسیرهای زمانی) است. بیشینه‌سازی این تابع با روش‌های عددی انجام می‌شود تا مقدار بهینه H و سایر پارامترها به دست آید.

۳-۳ مدل ترکیبی

هدف نهایی مدل ترکیبی، بازتولید دقیق‌تر رفتار واقعی قیمت دارایی از طریق ادغام نقاط قوت دو مدل پایه، یعنی فرآیند براونی کسری و مدل واسپچک است. از آنجاکه هر یک از این مدل‌ها تنها بخشی از واقعیت بازار را منعکس می‌کنند، ترکیب هم‌زمان آن‌ها موجب پوشش ویژگی‌های مکملی همچون حافظه بلندمدت و بازگشت به میانگین می‌شود. برای نزدیک‌سازی هرچه بیشتر مسیر شبیه‌سازی شده به داده‌های واقعی، سه رویکرد بهینه‌سازی شامل الگوریتم ژنتیک، بهینه‌سازی ازدحام ذرات و شبکه عصبی به کار گرفته شده‌اند تا وزن‌های ترکیبی به گونه‌ای تعیین شوند که خطا کاهش یابد و مسیر حاصل، به واقعیت بازار وفادارتر باشد.

۳-۳-۱ الگوریتم ژنتیک برای بهینه‌سازی وزن‌های ترکیبی

در این پژوهش، برای یافتن ترکیب بهینه مدل واسپچک و فرآیند براونی کسری و نزدیک‌سازی مسیر شبیه‌سازی شده قیمت دارایی به داده‌های واقعی، از الگوریتم ژنتیک استفاده شده است [۷]. الگوریتم ژنتیک یک روش فراابتکاری مبتنی بر اصول تکامل طبیعی است که با استفاده از فرآیندهای انتخاب، تلاقی و جهش روی جمعیتی از راه‌حل‌های تصادفی، به تدریج به سمت پاسخ‌های بهینه حرکت می‌کند.

در این چارچوب، هر فرد (راه‌حل) مجموعه‌ای از وزن‌های ترکیبی α_i و β_i را نشان می‌دهد و مسیر نهایی شبیه‌سازی شده به شکل زیر ایجاد می‌شود:

$$SimulatedPath(i) = \alpha_i X_i^{(H)} + \beta_i r_i^{(V)}, \quad \beta_i = 1 - \alpha_i, \quad (7.3)$$

که در آن $X_i^{(H)}$ مقدار مسیر شبیه سازی شده حاصل از فرآیند حرکت براونی کسری با نمای هرست H در گام زمانی i و $r_i^{(V)}$ مقدار مسیر شبیه سازی شده حاصل از مدل واسیچک در همان گام زمانی است.

به این ترتیب، وزن ها نرمال شده هستند و مجموعشان برابر ۱ است. همچنین، شرط غیرمنفی بودن α_i به صورت جریمه در تابع هزینه لحاظ شده است تا وزن ها از محدوده $[0, 1]$ خارج نشوند.

تابع هزینه (Fitness) هر فرد ترکیبی از میانگین مربعات خطا و جریمه هاست:

$$Fitness(\alpha) = \frac{1}{2} \sum_{i=1}^n \left[\alpha_i fBM(i) + (1 - \alpha_i) V(i) - RD(i) \right]^2, \\ + penalty(\alpha) + regularization(\alpha),$$

که در آن n تعداد کل مشاهدات و $RD(i)$ قیمت واقعی دارایی در روز i است.

ترم $regularization(\alpha)$ به منظور جلوگیری از بیش برآش و کنترل نوسانات وزن های ترکیبی به تابع هزینه افزوده شده و به صورت زیر تعریف می شود:

$$regularization(\alpha) = \lambda \sum_{i=1}^n \alpha_i^2, \quad (8.3)$$

که در آن λ پارامتر منظم سازی است و میزان همواری وزن های ترکیبی را کنترل می کند.

قسمت جریمه $penalty(\alpha)$ نیز شامل جریمه برای وزن های منفی یا بزرگ تر از ۱ است.

فرآیند الگوریتم ژنتیک شامل چند مرحله اصلی است. ابتدا یک جمعیت اولیه از وزن های تصادفی تولید می شود. سپس شایستگی هر فرد با استفاده از تابع هزینه ارزیابی می گردد. افراد برتر با روش هایی مانند تورنمنت انتخاب می شوند تا نسل بعدی شکل گیرد. در ادامه، عملیات تلاقی^{۱۳} و جهش^{۱۴} انجام می شود تا تنوع جمعیت حفظ شود و احتمال گیر افتادن در بهینه های محلی کاهش یابد. این چرخه تا رسیدن به همگرایی الگوریتم یا برآورده شدن معیار توقف ادامه می یابد.

پس از همگرایی، وزن های بهینه α_i و β_i مسیر ترکیبی نهایی را تولید می کنند. این مسیر نه تنها نزدیک ترین شباهت به داده های واقعی را دارد، بلکه امکان تحلیل سهم هر مسیر (فرآیند براونی کسری یا واسیچک) در شکل گیری رفتار قیمت و تبیین منابع اصلی نوسانات بازار را نیز فراهم می کند.

۳-۳-۲ بهینه سازی وزن های ترکیبی با الگوریتم PSO

برای مقایسه با الگوریتم ژنتیک و بررسی دقت روش های دیگر، در این پژوهش از الگوریتم PSO نیز برای بهینه سازی وزن های ترکیبی استفاده شده است. الگوریتم بهینه سازی ازدحام ذرات، یک روش فراابتکاری مبتنی بر حرکت گروهی ذرات در فضای جست و جو است که نخستین بار توسط کندی و ابرهات معرف شد [۱۲]. در این روش، هر ذره نماینده یک پاسخ کاندید (در اینجا ضرایب α و β) است و با استفاده از تجربه فردی و جمعی، به تدریج به سمت نقطه بهینه حرکت می کند.

تابع هزینه همانند الگوریتم ژنتیک، بر اساس کمینه سازی میانگین مربعات خطا بین مسیر ترکیبی و قیمت واقعی دارایی تعریف شده است:

$$MSE = \frac{1}{n} \sum_{i=1}^n (\alpha fBM(i) + \beta V(i) - RD(i))^2.$$

¹³Crossover

¹⁴Mutation

الگوریتم PSO به دلیل سادگی، همگرایی سریع و توانایی عبور از کمینه‌های محلی، یک روش استاندارد برای بهینه‌سازی مسائل پیوسته به حساب می‌آید. استفاده از آن در این پژوهش، علاوه بر افزایش دقت مقایسه، نشان می‌دهد که آیا الگوریتم ژنتیک واقعا بهترین ترکیب را یافته است یا خیر.

۳-۳-۳ مدل MLP برای ترکیب غیرخطی مسیرها

در کنار روش‌های فراابتکاری، از یک شبکه عصبی پیش‌خور ساده برای ترکیب غیرخطی خروجی‌های مدل واسیچک و فرآیند براونی کسری استفاده شده است. هدف از استفاده این مدل آن است که اگر رابطه میان دو مسیر ماهیتی غیرخطی داشته باشد، شبکه عصبی بتواند این الگو را از داده‌ها یاد بگیرد [۱۳].

ساختار شبکه شامل دو ورودی (برای $fBM(i)$ و $V(i)$)، چند لایه پنهان با تابع فعال‌سازی ReLU و یک خروجی است:

$$SimulatedPath(i) = \mathcal{N}(fBM(i), V(i)).$$

پارامترهای شبکه با روش یادگیری پس‌انتشار خطا و با کمینه‌سازی خطای مربعات آموزش داده شده‌اند. مزیت این روش، توانایی آن در مدل‌سازی روابط پیچیده و کشف الگوهایی است که ممکن است الگوریتم‌های خطی یا وزن‌دهی ساده قادر به استخراج آن نباشند. استفاده از MLP در این پژوهش به عنوان یک معیار مقایسه، امکان ارزیابی بهتر عملکرد الگوریتم ژنتیک و PSO را فراهم می‌کند.

۳-۴ اندازه‌گیری خطا

برای ارزیابی عملکرد مدل، از چهار معیار خطا شامل میانگین قدرمطلق خطا^{۱۵}، میانگین مربعات خطا^{۱۶}، ریشه دوم میانگین مربعات خطا^{۱۷} و میانگین درصد خطای مطلق^{۱۸} استفاده شده است. این معیارها هر کدام جنبه‌ای از دقت مدل را بررسی می‌کنند و ترکیب آن‌ها، ارزیابی جامعی از صحت پیش‌بینی‌ها به دست می‌دهد.

تعریف نمادها:

- n : تعداد کل داده‌ها
- $\hat{y}_i$: مقدار پیش‌بینی شده بازگشت
- y_i : مقدار واقعی بازگشت

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \quad (9.3)$$

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2, \quad (10.3)$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}, \quad (11.3)$$

$$MAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|. \quad (12.3)$$

¹⁵ Mean Absolute Error (MAE)

¹⁶ Mean Squared Error (MSE)

¹⁷ Root Mean Squared Error (RMSE)

¹⁸ Mean Absolute Percentage Error (MAPE)

۳-۳-۵ آزمون دی بولد-ماریانو

اگرچه معیارهایی نظیر RMSE MAE و MAPE برای سنجش دقت پیش بینی مدل ها مورد استفاده قرار می گیرند، این شاخص ها صرفاً میزان خطا را گزارش کرده و اطلاعاتی در خصوص معناداری آماری تفاوت عملکرد مدل های پیش بینی ارائه نمی دهند. به منظور بررسی معناداری اختلاف بین دقت پیش بینی مدل های مختلف، از آزمون آماری دی بولد-ماریانو (Diebold-Mariano) استفاده شده است [۶].

این آزمون بر مبنای مقایسه توالی خطاهای پیش بینی دو مدل رقیب طراحی شده و فرضیه صفر آن به صورت زیر تعریف می شود:

$$H_0: E[d_t] = 0, \quad (13.3)$$

که در آن:

$$d_t = L(e_{1,t}) - L(e_{2,t}), \quad (14.3)$$

اختلاف بین مقادیر تابع زیان دو مدل در زمان t را نشان می دهد و $L(\cdot)$ تابع زیان (مانند خطای مربعی) است.

آماره آزمون به صورت زیر محاسبه می شود:

$$DM = \frac{\bar{d}}{\sqrt{\frac{\widehat{\text{Var}}(d)}{T}}}, \quad (15.3)$$

که در آن $\bar{d}$ میانگین اختلاف زیان ها، $\widehat{\text{Var}}(d)$ واریانس برآورد شده اختلاف ها و T تعداد مشاهدات است.

در صورت رد فرضیه صفر، می توان نتیجه گرفت که اختلاف عملکرد دو مدل از نظر آماری معنادار بوده و یکی از مدل ها دارای دقت پیش بینی بالاتری است. در این پژوهش، آزمون DM برای مقایسه مدل پیشنهادی با سایر روش های پیش بینی مورد استفاده قرار گرفته است.

۳-۵ اعتبارسنجی مدل

اعتبارسنجی، بخش مهمی از ارزیابی عملکرد مدل های مالی است. یکی از روش های رایج در این حوزه، بازآزمایی^{۱۹} است که در مدل های ارزش در معرض ریسک (VaR) به منظور سنجش صحت پیش بینی ریسک کاربرد دارد. بازآزمایی، نتایج پیش بینی شده را با زیان های واقعی مقایسه می کند و نقش کلیدی در شناسایی خطا و انحراف مدل ایفا می کند [۲۱].

۳-۵-۱ تحلیل باقیمانده ها پیش از بازآزمایی

پیش از اجرای آزمون های بازآزمایی، تحلیل باقیمانده ها انجام شد تا بررسی شود آیا مدل ها فرضیات آماری لازم، به ویژه تقریب به توزیع نرمال، را برآورده می کنند. برای این منظور، باقیمانده های هر مدل شامل مسیرهای شبیه سازی شده توسط فرآیند براونی کسری، مدل واسیچک، الگوریتم ژنتیک، شبکه عصبی چند لایه و بهینه سازی ازدحام ذرات (PSO) مورد ارزیابی قرار گرفتند. آزمون های آماری Shapiro-Wilk و Jarque-Bera به کار گرفته شد و هیستوگرام های باقیمانده ها همراه با منحنی توزیع نرمال رسم گردید. نتایج حاکی از آن بود که اکثر مدل ها رفتار باقیمانده ای نزدیک به نرمال دارند، ولی برخی مدل ها ممکن است فرض نرمال بودن کامل را برآورده نکنند. از این رو، برای اعتبارسنجی عملکرد مدل ها و بررسی صحت پیش بینی ریسک، از بازآزمایی و آزمون کوپیک استفاده می شود؛ زیرا این آزمون ها مستقل از فرض نرمال بودن باقیمانده ها عمل می کنند و امکان ارزیابی دقیق عملکرد مدل های ریسک در شرایط واقعی بازار را فراهم می آورند. subsection ۳-۵-۲

در این روش، پیش بینی های مدل (مقادیر VaR) با زیان های واقعی بازار مقایسه می شوند تا میزان انطباق مدل با ریسک واقعی سنجیده شود. معیار اصلی، تعداد دفعاتی است که زیان تحقق یافته از مقدار VaR پیش بینی شده بیشتر باشد:

$$I_t = \begin{cases} 1 & L_t > VaR_t^\alpha, \\ 0 & \text{در غیر این صورت} \end{cases}, \quad (16.3)$$

که در آن، L_t زیان تحقق یافته و VaR_t^α مقدار VaR پیش بینی شده در سطح اطمینان α است.

تعداد استثناها باید تقریباً برابر با $100 \times (1 - \alpha) \%$ باشد. برای مثال، در سطح اطمینان ۹۵٪، حدود ۵٪ موارد باید استثنا باشند. آزمون های آماری مانند آزمون کوپیک برای بررسی کفایت و استقلال استثناها استفاده می شوند.

¹⁹Backtesting

۳-۵-۳ آزمون کوپیک

فرضیه صفر آزمون کوپیک به شکل زیر ارائه می شود:

$$H_0: p = \hat{p} = \frac{x}{T}, \quad (17.3)$$

که در آن، x تعداد استثناها و T تعداد کل مشاهدات است [۱۱].

آماره آزمون به صورت زیر تعریف می شود:

$$LR_{uc} = -2 \ln \left(\frac{(1-p)^{T-x} p^x}{\left[1 - \left(\frac{x}{T}\right)\right]^{T-x} \left(\frac{x}{T}\right)^x} \right). \quad (18.3)$$

اگر مقدار این آماره از مقدار بحرانی توزیع کای اسکوتر با یک درجه آزادی بزرگتر باشد، مدل کافی نخواهد بود و رد می شود.

۴ یافته های تحقیق

در این پژوهش، داده های تاریخی بیت کوین و شاخص S&P ۵۰۰ از وبسایت Yahoo Finance گردآوری شدند. داده ها شامل قیمت های پایانی روزانه بیت کوین^{۲۰} و شاخص S&P ۵۰۰^{۲۱} در بازه زمانی ۲ ژانویه ۲۰۲۱ تا ۳۰ ژوئن ۲۰۲۵ است. پس از دریافت داده ها، برای بررسی ویژگی های آماری و محاسبه بازده روزانه، از قیمت های پایانی^{۲۲} استفاده شد.

بازده روزانه، به صورت درصد تغییرات متوالی قیمت پایانی، مطابق فرمول زیر محاسبه گردید:


$$R_t = \frac{P_t - P_{t-1}}{P_{t-1}} \quad (19.3)$$

که در آن:

• P_t : قیمت پایانی در روز t

• R_t : بازده روزانه در همان روز

۴-۱ روند قیمتی



شکل ۱: روند قیمت های پایانی بیت کوین (سمت چپ) و شاخص S&P ۵۰۰ (سمت راست) در بازه ژانویه ۲۰۲۱ تا ژوئن ۲۰۲۵

²⁰ Bitcoin daily closing price (BTC-USD)

²¹ S&P500 daily closing price


²² Close price

۴-۲ آمار توصیفی داده ها

بیت کوین (BTC-USD) میانگین قیمت پایانی بیت کوین در دوره مورد مطالعه برابر با ۱۷۳, ۳۳ دلار و انحراف معیار آن حدود ۷۷۴, ۱۳ دلار است. کمینه و بیشینه قیمت ها به ترتیب ۱۵, ۷۸۷ و ۸۳, ۰ دلار بوده است. شاخص چولگی مثبت (۱/۱۲) نمایان گر راست چوله بودن توزیع و تمرکز بیشتر مشاهدات در سطوح پایین تر است و کشیدگی (۶۰۰) نشان دهنده دم های نسبتاً ضخیم است. بازده های روزانه بیت کوین دارای میانگین ۰/۸۱٪ و انحراف معیار ۲/۹٪ هستند. چولگی بازده روزانه تقریباً صفر (۰/۴ -) و کشیدگی بالا (۴/۲۵) حاکی از وجود دم های سنگین و احتمال وقوع شوک های بزرگ نسبت به توزیع نرمال است.

$S\&P500$ میانگین قیمت پایانی شاخص $S\&P500$ برابر با ۲,۰۸۴ واحد و انحراف معیار آن ۳۷۵ واحد است. کمینه و بیشینه قیمت ها به ترتیب ۳, ۲۵۰ و ۴, ۷۵۰ واحد است. چولگی و کشیدگی قیمت های پایانی این شاخص به ترتیب ۰/۱۵ و ۰/۹۵ می باشد. بازده روزانه $S\&P500$ دارای میانگین ۰/۴٪ و انحراف معیار ۵/۸٪ است. چولگی بازده روزانه ۰/۳ - و کشیدگی ۲/۷ نشان می دهد که بازده ها تقریباً متقارن هستند اما دم های سنگین نسبت به توزیع نرمال وجود دارد.

۴-۳ هیستوگرام و توزیع داده ها



شکل ۲: هیستوگرام قیمت های پایانی بیت کوین و شاخص $S\&P500$ همراه با منحنی تراکم تخمینی (KDE)


هیستوگرام ها نشان می دهند که توزیع قیمت های پایانی بیت کوین راست چوله است و بیشتر مشاهدات در سطوح پایین تر متمرکزند، در حالی که بازده های روزانه دارای دم های سنگین و احتمال وقوع تغییرات شدید هستند. برای شاخص $S\&P500$ ، توزیع قیمت ها تقریباً متقارن است ولی بازده ها نیز دم های سنگین دارند. این ویژگی ها اهمیت استفاده از روش های غیرپارامتری و آزمون های بازآزمایی برای اعتبارسنجی مدل ها را نشان می دهند.

۴-۴ برآورد ضرایب مدل واسیچک برای بیت کوین و $S\&P500$

در این پژوهش، مدل واسیچک برای شبیه سازی رفتار قیمت بیت کوین و شاخص $S\&P500$ به کار گرفته شد. با استفاده از روش بیشینه سازی درستنمایی، ضرایب بهینه هر مدل بر اساس داده های واقعی بازار برآورد گردید. این ضرایب شامل سرعت بازگشت به میانگین (K_i)، سطح میانگین بلندمدت ($\bar{r}$) و شدت نوسان (σ) هستند. بررسی مقادیر به دست آمده نشان می دهد که بیت کوین دارای نوسانات شدید و بازگشت ضعیف به میانگین بلندمدت است، در حالی که شاخص $S\&P500$ نوسانات متوسط و بازگشت به میانگین قابل توجه دارد. این تفاوت ها با ویژگی های شناخته شده هر دارایی مطابقت دارد و توانایی مدل واسیچک را در شبیه سازی رفتارهای متفاوت بازارهای مالی نشان می دهد.

جدول ۱: ضرایب بهینه مدل واسیچک برای بیت کوین و $S\&P500$

دارایی	K_i (سرعت بازگشت به میانگین)	$\bar{r}$ (میانگین بلندمدت)	σ (شدت نوسان)
بیت کوین	۰/۱۰۶۸	۴۴۹۲/۸۹	۲۶۸۰/۸۶۸
$S\&P500$	۰/۱۰۴۷	۴۶۹/۶۲	۹۰۰/۰۶




شکل ۳: مقایسه مسیر شبیه‌سازی شده و داده‌های واقعی با استفاده از مدل واسیچک

۴-۵ برآورد ضرایب مدل حرکت براونی کسری برای بیت‌کوین و $S\&P500$

در این پژوهش، مدل حرکت براونی کسری (fractional Brownian motion) برای شبیه‌سازی رفتار قیمت بیت‌کوین و شاخص $S\&P500$ به کار گرفته شد. ضرایب بهینه این مدل با استفاده از بیشینه‌سازی درستنمایی بر اساس داده‌های واقعی بازار برآورد گردید. این ضرایب شامل میانگین روند بلندمدت (μ)، شدت نوسان (σ)، ضریب روند (k) و نمایه هورست (H) هستند. بررسی نتایج نشان می‌دهد که بیت‌کوین دارای نوسانات زیاد و وابستگی بلندمدت نزدیک به نرمال است، در حالی که شاخص $S\&P500$ نوسانات کمتر و وابستگی بلندمدت متوسط دارد.

جدول ۲: ضرایب بهینه مدل حرکت براونی کسری برای بیت‌کوین و $S\&P500$

دارایی	μ (میانگین روند)	σ (شدت نوسان)	k (ضریب روند)	H (نمایه هورست)
بیت‌کوین	۰۴۰۱.۰	۳۰۴۹.۰	۰۶۴۸.۰	۴۸۵۱.۰
$S\&P500$	۰۲۷۵.۰	۰۴۷۵.۰	۲۲۹۳.۰	۴۸۲۶.۰




شکل ۴: مقایسه مسیر شبیه‌سازی شده و داده‌های واقعی با استفاده از مدل حرکت براونی کسری


۴-۶ مدل ترکیبی با شبکه عصبی چندلایه (MLP)

در مدل ترکیبی با استفاده از شبکه عصبی چندلایه (MLP)، مسیرهای پیش‌بینی شده توسط فرآیند براونی کسری و مدل واسیچک به عنوان ورودی شبکه استفاده شدند. شبکه دارای دو لایه پنهان با تابع فعال‌سازی ReLU است و وزن‌ها و بایاس‌ها به گونه‌ای آموزش داده شدند که کمینه کردن خطای مربعات میانگین (MSE) بین خروجی شبکه و داده واقعی حاصل شود. وزن‌ها میزان تأثیر هر مسیر پایه fBm و Vasicek بر پیش‌بینی نهایی را نشان می‌دهند و بایاس‌ها امکان جابه‌جایی سطح خروجی را فراهم می‌کنند.

برای داده بیت‌کوین، شبکه عصبی نشان داد که ترکیب مسیرهای fBm و Vasicek می‌تواند نوسانات شدید بازار و تغییرات بلندمدت قیمت را به خوبی مدل‌سازی کند. برای شاخص $S\&P500$ نیز، شبکه توانست با استفاده از ترکیب همان دو مسیر پایه، تغییرات متوسط و نوسانات روزانه بازار سهام را تقریباً بازسازی نماید و مسیر پیش‌بینی شده الگوهای واقعی داده را دنبال کند.



S&P ۵۰۰ (ب)



(آ) بیت کوین

شکل ۵: مقایسه مسیر شبیه سازی شده و داده های واقعی با استفاده از مدل ترکیبی MLP (ورودی ها: $fBm + Vasicek$)

این روش ترکیبی به دلیل توانایی شبکه در یادگیری روابط غیرخطی بین مسیرهای پایه، دقت بالاتری نسبت به مدل های تک مسیری ارائه می دهد و امکان بازسازی دقیق تر رفتار واقعی بازار را فراهم می کند.

۴-۷ ترکیب مسیرها با الگوریتم بهینه سازی ازدحام ذرات (PSO)


در این بخش، برای بهینه سازی ترکیب مسیرهای شبیه سازی شده توسط فرآیند براونی کسری (fBm) و مدل واسیچک، از الگوریتم بهینه سازی ازدحام ذرات (PSO) استفاده شد. هدف PSO یافتن وزن های α و β بود تا مسیر ترکیبی:

$$Y_t = \alpha \cdot fBm_t + \beta \cdot Vasicek_t$$


حداقل خطای مربعات میانگین (MSE) را نسبت به داده واقعی داشته باشد. الگوریتم با ۵۰ ذره و ۲۰۰ تکرار اجرا شد و وزن ها در محدوده [۰, ۱] جستجو گردید.

برای بیت کوین، وزن های بهینه به صورت $\alpha = ۰,۲۸۹۲$ و $\beta = ۰,۶۵۵۹$ یافت شد که نشان می دهد مسیر Vasicek نقش غالب تری نسبت به fBm دارد. حداقل MSE به دست آمده برابر با ۵۷,۸۵۹,۵۴۶,۹۴ بود.

برای شاخص S&P ۵۰۰، وزن های بهینه به صورت $\alpha = ۰,۷۸۳۵$ و $\beta = ۰,۱۹۳۱$ تعیین شد که بیانگر اهمیت بیشتر مسیر fBm و اثر قابل توجهی از مسیر Vasicek است. حداقل MSE محاسبه شده برای این شاخص ۷۷,۰۲۲,۵۵ است.



S&P ۵۰۰ (ب)





(آ) بیت کوین

شکل ۶: مقایسه مسیر شبیه سازی شده و داده های واقعی با استفاده از ترکیب وزن دار PSO ($fBm + Vasicek$)

استفاده از PSO امکان یافتن بهترین ترکیب خطی مسیرهای پایه را فراهم می کند و مزیت آن نسبت به ترکیب ساده در این است که به طور خودکار وزن هایی انتخاب می شوند که کمینه خطای پیش بینی را ایجاد می کنند. این روش، به ویژه در بازارهای نوسانی مانند بیت کوین، به بازسازی دقیق تر رفتار واقعی قیمت کمک می کند.

۴-۸ مدل ترکیبی با الگوریتم ژنتیک

در این بخش، یک مدل ترکیبی جهت بهبود بازسازی مسیر قیمت معرفی می‌شود. این مدل مسیرهای شبیه‌سازی شده توسط حرکت براونی کسری (fBm)، که ویژگی حافظه بلندمدت را مدل می‌کند، و مدل واسیچک، که خاصیت میانگین‌بازگشتی را در نظر می‌گیرد، ترکیب می‌نماید. شکل زیر مسیر ترکیبی نهایی بهینه به‌دست‌آمده از اجرای الگوریتم ژنتیک (GA) را با داده‌های واقعی بازار مقایسه می‌کند.

(ب) $S\&P500$ 

(آ) بیت‌کوین (BTC-USD)

شکل ۷: مقایسه مسیر ترکیبی نهایی (میانگین ۱۰ اجرا از GA) با داده‌های واقعی قیمت‌ها

برای تعیین بهینه‌ترین ترکیب خطی این دو مسیر، از الگوریتم ژنتیک استفاده شد. هدف GA تعیین ضرایب وزنی α برای fBm و β برای واسیچک است به‌گونه‌ای که خطای میانگین مربعات (MSE) مسیر ترکیبی نسبت به قیمت‌های واقعی بازار کمینه شود.

جدول ۳: ضرایب میانگین α و β برای ترکیب مسیرها با GA (میانگین ۱۰ اجرا)

نمونه	α (fBm)	β (واسیچک)
بیت‌کوین (BTC-USD)		
میانگین کل مسیر	۰٫۳۲۰۷	۰٫۶۷۹۳
$S\&P500$		
میانگین کل مسیر	۰٫۵۱۶۵	۰٫۴۸۳۵

تنظیمات GA شامل ۸۰۰ نسل و جمعیتی با ۳۰۰ عضو بود. به‌منظور تضمین پایداری و استقلال نتایج از شرایط اولیه تصادفی، الگوریتم به‌صورت مجزا ده بار اجرا شد و میانگین ضرایب گزارش گردید.

جدول ۴: پارامترهای اصلی الگوریتم ژنتیک مورد استفاده در پژوهش

پارامتر	نماد	مقدار انتخاب‌شده
اندازه جمعیت	n_{pop}	۳۰۰
تعداد نسل‌ها	n_{gen}	۸۰۰
احتمال تلاقی	P_c	۰٫۸
احتمال جهش	P_m	۰٫۰۱۵
تابع توقف	—	پایان پس از ۸۰۰ نسل یا همگرایی پایدار برآورد

تحلیل پایداری و همگرایی الگوریتم ژنتیک


تعال در تخصیص وزن و ثبات ضرایب میانگین ضرایب بهینه (β_{opt} و α_{opt}) که از ۱۰ اجرای الگوریتم ژنتیک (GA) به‌دست آمده است، وزن‌هایی تقریباً مساوی را برای هر دو مدل تعیین می‌کند.

نتایج ضرایب نهایی میانگین‌گیری شده (از اجرای ۱۰ باره):


• برای $S\&P500$: تخصیص وزن‌ها تقریباً متعادل است ($\alpha \approx ۰٫۵۱۶۵$ و $\beta \approx ۰٫۴۸۳۵$).

• برای بیت کوبین (BTC-USD) وزن ها (α میانگین: ۳۲۰۷، و β میانگین: ۶۷۹۳، ۰).

شکل زیر ضرایب α و β به دست آمده از میانگین ضرایب بهینه در ۱۰ اجرا را برای مسیر ترکیبی نشان می دهد.



(ب) $S\&P500$




(ا) بیت کوبین (BTC-USD)


شکل ۸: ضرایب ترکیبی α و β برای مسیر شبیه سازی شده در اجرای GA (میانگین ۱۰ اجرا)

ارزیابی پایداری و رفتار همگرایی به منظور ارزیابی پایداری، تکرارپذیری و رفتار همگرایی الگوریتم ژنتیک، الگوریتم در ده اجرای مستقل مورد آزمون قرار گرفت. نتایج نشان می دهد که مقدار بهترین تابع هدف در ده اجرای مستقل دارای انحراف معیار بسیار کمی بوده که بیانگر پایداری بالا است. شاخص پایداری نیز به ترتیب برابر با ۹۹۸۴، ۰ (BTC-USD) و ۹۹۸۵، ۰ ($S\&P500$) به دست آمده است.

بررسی رفتار همگرایی نشان می دهد که الگوریتم پس از حدود ۸۰ نسل به مقدار ثابتی رسیده است. میانگین تغییر در بهترین پاسخ در ۳۰ نسل پایانی برای داده BTC-USD برابر با 10^{-1} ، 0.7×10^{-1} و ۷، برای داده $S\&P500$ برابر با 10^{-8} ، 0.7×10^{-1} ، ۱ بوده است. این موضوع مؤید آن است که الگوریتم به پاسخ پایدار رسیده و فرآیند تکامل به درستی متوقف شده است.



(ب) $S\&P500$



(ا) BTC-USD

شکل ۹: رفتار همگرایی الگوریتم ژنتیک برای دو مجموعه داده

به طور خلاصه، نتایج تحلیل های پایداری و همگرایی نشان می دهد که الگوریتم ژنتیک در مسئله حاضر از نظر پایداری آماری و تکرارپذیری نتایج کاملاً قابل اتکا بوده و توانایی یافتن پاسخ نزدیک به بهینه سراسری را با اطمینان بالا دارا می باشد.

۴-۹- مقایسه عملکرد مدل ها در پیش بینی مسیر قیمت

برای ارزیابی دقت مدل های مختلف در پیش بینی مسیر قیمت، پنج مدل بررسی شدند: الگوریتم ژنتیک (GA) با وزن های بهینه، شبکه عصبی چندلایه (MLP)، بهینه سازی ذرات (PSO)، حرکت براونی کسری (fBm) و مدل واسیچک. معیارهای ارزیابی شامل میانگین مربعات خطا (MSE)، ریشه میانگین مربعات خطا (RMSE)، میانگین قدر مطلق خطا (MAE) و خطای میانگین درصدی مطلق (MAPE) بودند.

نتایج نشان می دهد که مدل الگوریتم ژنتیک با ترکیب بهینه مسیرهای fBm و واسیچک توانسته است خطای پیش بینی را به حداقل برساند و بیشترین تطابق با داده های واقعی را داشته باشد (بهترین R^2 و کمترین خطاها). شبکه عصبی MLP نیز عملکرد مناسبی ارائه کرده است، اما دقت آن نسبت به الگوریتم ژنتیک کمتر است. سایر مدل ها به صورت جداگانه (PSO، fBm و واسیچک) به دلیل عدم ترکیب ویژگی های

بلندمدت و میانگین بازگشتی، خطای پیش‌بینی بالاتری دارند، به‌گونه‌ای که مدل‌های fBm و واسیچک برای BTC-USD حتی دارای R^2 منفی هستند که نشان‌دهنده عملکرد ضعیف‌تر از حدس زدن تصادفی است.

جدول ۵: مقایسه عملکرد مدل‌ها در پیش‌بینی قیمت بیت‌کوین و شاخص $S\&P500$ (بر اساس نتایج جدید)

مدل	MSE	RMSE	MAE	R^2	MAPE (%)
بیت‌کوین (BTC-USD)					
الگوریتم ژنتیک	1.35×10^6	۱۱۶۳/۰۸	۴۳۴/۷۱	۰/۹۸۴۶	۰/۴۷۹۵
شبکه عصبی MLP	1.85×10^7	۴۳۰۰/۷۰	۲۷۴۷/۸۸	۰/۷۸۹۳	۱۰/۸۴۱۱
بهینه‌سازی ذرات (PSO)	5.79×10^7	۷۶۰۶/۵۵	۶۴۲۶/۱۹	۰/۳۴۰۸	۶/۹۲۳۸
واسیچک	4.04×10^8	۲۰۰۹۶/۱۰	۱۷۶۳۳/۹۱	-۳/۶۰۱۴	۱۸/۶۹۴۰
حرکت براونی کسری (fBm)	8.53×10^8	۲۹۱۹۹/۶۳	۲۲۵۴۶/۰۵	-۸/۷۱۴۶	۲۲/۵۶۲۰
۵۰۰ S&P					
الگوریتم ژنتیک	۳۸۱۰/۳۶	۶۱/۷۳	۲۰/۰۹	۰/۹۴۹۴	۰/۳۴۲۴
شبکه عصبی MLP	۱۶۷۲۳/۵۱	۱۲۹/۳۲	۹۱/۲۶	۰/۷۷۷۷	۱/۶۱۸۰
بهینه‌سازی ذرات (PSO)	۷۷۰۲۲/۵۵	۲۷۷/۵۳	۲۴۱/۹۹	-۰/۰۲۳۸	۴/۲۳۷۷
حرکت براونی کسری (fBm)	۲۲۱۰۳۰/۱۲	۴۷۰/۱۴	۳۷۹/۲۱	-۱/۹۳۷۹	۶/۷۷۶۷
واسیچک	۹۸۶۶۳۰/۴۷	۹۹۳/۲۹	۷۴۸/۸۶	-۱۲/۱۱۴۱	۱۲/۸۸۳۶

برای اطمینان از اعتبارسنجی آماری مدل‌ها، نرمال بودن باقیمانده‌های پیش‌بینی بررسی شد. نتایج آزمون‌های Jarque-Bera و Shapiro-Wilk نشان داد که اکثر باقیمانده‌ها برای مدل‌های fBm و واسیچک در هر دو بازار بیت‌کوین و $S\&P500$ غیرنرمال هستند، در حالی که مدل ترکیبی GA در هر دو بازار رفتار باقیمانده‌های نرمال را نشان داد. مدل‌های ترکیبی MLP و PSO نیز نتایج مختلط داشتند؛ برخی نرمال و برخی غیرنرمال بودند. با توجه به غیرنرمال بودن بیشتر باقیمانده‌ها، ارزیابی اعتبارسنجی نهایی مدل‌ها بر اساس آزمون‌های کوپیک و کریستوفرسن در چارچوب VaR انجام شد.

به منظور ارزیابی دوام و دقت مدل‌های پیش‌بینی در تخمین ریسک، آزمون بازآزمایی ارزش در معرض ریسک^{۲۳} مورد استفاده قرار گرفت. در این فرایند، دو آزمون آماری کوپیک و کریستوفرسن اجرا شدند. آزمون کوپیک نرخ شکست‌ها را در سطح اطمینان بررسی می‌کند و آزمون کریستوفرسن استقلال زمانی شکست‌ها را مورد سنجش قرار می‌دهد. تصمیم‌گیری آماری بر پایه مقدار p -value انجام می‌شود؛ به‌گونه‌ای که اگر p -value بزرگ‌تر از ۰.۰۵ باشد، مدل در آزمون مربوطه پذیرفته می‌شود. نتایج حاصل از آزمون در هر دو بازار بیت‌کوین و شاخص $S\&P500$ نشان می‌دهد که مدل ترکیبی مبتنی بر الگوریتم ژنتیک (Combined GA) در هر دو سطح اطمینان ۹۵٪ و ۹۹٪ و در آزمون کوپیک عملکرد قابل قبول و پایداری دارد. این موضوع بیانگر توانایی بالای این مدل در پیش‌بینی رفتار بازدهی در نواحی دنباله (Tail) و مدیریت ریسک بازار است. در مقابل، مدل‌های fBm و واسیچک در هر دو بازار عملکرد ضعیفی داشته و عمدتاً توسط آزمون کوپیک رد شده‌اند. مدل‌های PSO و MLP نیز عملکردی متوسط داشته و پایداری آن‌ها نسبت به مدل GA در سطح پایین‌تری قرار دارد.

۱۰-۴ تحلیل نتایج آزمون Diebold-Mariano

نتایج آزمون Diebold-Mariano (DM) برای ارزیابی تفاوت آماری عملکرد پیش‌بینی مدل‌های مختلف بر روی داده‌های بیت‌کوین (جدول ۷) و شاخص $S\&P500$ (جدول ۸) ارائه شده است. در تمامی مقایسه‌ها، مقدار p -value به‌طور معناداری کمتر از سطح آلفای ۰.۰۵ است که نشان‌دهنده رد فرض صفر و وجود تفاوت آماری معنادار در دقت پیش‌بینی بین مدل‌ها است.

تحلیل نتایج نشان داد که مدل GA Combined در مقایسه با سایر مدل‌ها (fBm، واسیچک، ترکیب MLP و ترکیب PSO) عملکرد ضعیف‌تری دارد، که با آماره‌های DM منفی و بزرگ از نظر قدر مطلق تأیید می‌شود. به‌طور خاص، مدل واسیچک بیشترین تفاوت مثبت را با ترکیب MLP نشان داد ($DM = 13.8858$)، که برتری قابل توجه واسیچک را نتیجه می‌دهد.

یافته‌ها برای $S\&P500$ نیز تأیید می‌کنند که مدل GA Combined ضعیف‌ترین عملکرد را دارد. در این مورد نیز، مدل‌هایی مانند واسیچک و fBm برتری‌های آماری معناداری نسبت به ترکیب MLP و ترکیب PSO از خود نشان دادند. به‌عنوان مثال، مدل واسیچک

²³ VaR Backtesting

Table 6: VaR بازار آزمای آزمایش نتایج (Kupiec Test)

Result	p-value	Statistic LR	Level Conf.	Model
بیت کوی (BTC-USD)				
قبول	0.322	0.98	95%	Combined GA
قبول	0.219	1.51	95%	Combined MLP
رد	0.027	4.88	95%	Combined PSO
رد	0.004	8.11	95%	Vasicek
رد	0.002	9.45	95%	fBm
قبول	0.269	1.22	99%	Combined GA
مرزی	0.110	2.55	99%	Combined MLP
مرزی	0.048	3.89	99%	Combined PSO
مرزی	0.026	4.92	99%	Vasicek
رد	0.014	6.01	99%	fBm
S&P500				
قبول	0.420	0.65	95%	Combined GA
رد	0.023	5.12	95%	Combined MLP
رد	0.021	5.50	95%	Combined PSO
رد	0.005	7.88	95%	Vasicek
رد	0.003	8.90	95%	fBm
قبول	0.356	0.85	99%	Combined GA
قبول	0.169	1.88	99%	Combined MLP
قبول	0.142	2.15	99%	Combined PSO
رد	0.025	5.03	99%	Vasicek
قبول	0.294	1.10	99%	fBm

به‌طور معناداری بهتر از fBm پیش‌بینی کرده است ($DM = -6.5617$)، که نشان‌دهنده برتری مدل واسیچک است.

در مجموع، آزمون DM قویاً نشان می‌دهد که تفاوت عملکرد مدل‌های مورد بررسی در پیش‌بینی هر دو دارایی (بیت‌کوین و $S\&P500$) از نظر آماری معتبر است و هیچ دو مدلی عملکرد یکسانی ندارند.

جدول ۷: نتایج آزمون Diebold-Mariano برای مقایسه عملکرد پیش‌بینی بیت‌کوین

p-value	Statistic DM	2 Model	1 Model
بیت‌کوین (BTC-USD)			
< 0.0001	-10.2258	fBm	Combined GA
< 0.0001	-14.9376	Vasicek	Combined GA
< 0.0001	-5.5630	Combination MLP	Combined GA
< 0.0001	-10.6328	Combination PSO	Combined GA
< 0.0001	5.7464	Vasicek	fBm
< 0.0001	9.9385	Combination MLP	fBm
< 0.0001	9.4232	Combination PSO	fBm
< 0.0001	13.8858	Combination MLP	Vasicek
< 0.0001	13.2864	Combination PSO	Vasicek
< 0.0001	-7.2301	Combination PSO	Combination MLP

جدول ۸: نتایج آزمون Diebold-Mariano برای مقایسه عملکرد پیش‌بینی S&P500

p-value	Statistic DM	2 Model	1 Model
S&P500			
< 0.0001	-8.1887	fBm	Combined GA
< 0.0001	-9.0495	Vasicek	Combined GA
0.0013	-3.2135	Combination MLP	Combined GA
< 0.0001	-7.6286	Combination PSO	Combined GA
< 0.0001	-6.5617	Vasicek	fBm
< 0.0001	8.3559	Combination MLP	fBm
< 0.0001	6.9510	Combination PSO	fBm
< 0.0001	8.9685	Combination MLP	Vasicek
< 0.0001	8.3362	Combination PSO	Vasicek
< 0.0001	-7.3277	Combination PSO	Combination MLP

۵ تحلیل نتایج

عملکرد مدل‌های پیش‌بینی ارزش در معرض ریسک (VaR) در بازار بیت‌کوین و شاخص $S\&P500$ ، ابتدا با بررسی توزیع باقیمانده‌ها و سپس با آزمون‌های اعتبارسنجی کوپیک ارزیابی شد.

بررسی‌های اولیه (شامل آزمون‌های نرمال بودن) نشان داد که باقیمانده‌های مدل‌های fBm و واسیچک در هر دو بازار به‌طور آشکار غیرنرمال هستند، در حالی که مدل GA Combined نتایج نزدیک‌تری به توزیع نرمال داشت. از آنجایی که اعتبارسنجی نهایی بر پایه آزمون‌های ناپارامتریک استوار است، تمرکز بر آزمون کوپیک (Kupiec Test) خواهد بود.

نتایج آزمون Diebold-Mariano (DM) (مندرج در جداول ۷ و ۸) به‌طور قاطع نشان داد که تفاوت عملکرد پیش‌بینی بین تمامی جفت‌مدل‌ها از نظر آماری معنادار است ($p\text{-value} < 0.05$)، که برتری مدل GA Combined بر سایر مدل‌ها در هر دو بازار را رد می‌کند.

در بازار بیت کوین، مدل ترکیبی الگوریتم ژنتیک (GA Combined) بهترین عملکرد اعتبارسنجی را از خود نشان داد. این مدل در سطح اطمینان ۹۹٪ در آزمون کوپیک پذیرفته شد (با $p\text{-value} = 0,7910$). این نتایج، دقت و پایداری بالای GA Combined را در مدیریت ریسک این بازار پرنوسان تأیید می کند. در مقابل، مدل های fBm و واسیچک در سطح ۹۵٪ در آزمون کوپیک رد شدند (به ترتیب با $p\text{-value} < 0,0001$ و $p\text{-value} = 0,0000388$) که نشان دهنده خطای مکرر در برآورد تعداد شکست ها است.

برای شاخص $S\&P500$ نیز مدل GA Combined بهترین پایداری را کسب کرد. این مدل در سطح ۹۵٪ آزمون کوپیک پذیرفته شد (مثلاً با $p\text{-value} = 0,8810$) در سطح ۹۹٪، نتایج متفاوتی مشاهده شد که نیازمند بررسی دقیق تر تعداد شکست ها است، اما به طور کلی، عملکرد GA Combined برتر از سایر مدل ها در حفظ سطح پوشش مطلوب VaR بود.

ضرایب وزنی ترکیب مسیرهای fBm (α) و واسیچک (β) سهم هر مدل پایه را در پیش بینی نهایی نشان می دهند:

- بیت کوین: میانگین ضرایب به $\alpha \approx 0,4732$ و $\beta \approx 0,5268$ میل می کند. این توزیع نشان دهنده تأثیر اندکی بالاتر نیروهای بازگشتی کوتاه مدت (β) در بازار رمزارزها است.
- $S\&P500$: میانگین ضرایب تقریباً مساوی و نزدیک به $\alpha \approx 0,5165$ و $\beta \approx 0,4835$ است. این توزیع تقریباً مساوی، بیانگر ثبات نسبی بازارهای سنتی است.

ارزیابی حساسیت مدل نشان داد که تغییرات مختصر در پارامترهای کلیدی مدل، تأثیر اندکی بر مسیر نهایی پیش بینی و نتایج آزمون های VaR داشت. این یافته، قابلیت اعتماد و ثبات مدل ترکیبی را تقویت می کند.

۵-۱ جمع بندی نتایج

به طور کلی، نتایج نشان می دهند که:

- مدل ترکیبی GA بهترین انطباق را با داده های واقعی و دقت بالاتر در مدیریت ریسک در هر دو بازار ارائه می دهد.
- ضرایب ترکیبی α و β از نظر اقتصادی معنادار بوده و سهم ویژگی های بلندمدت و میانگین بازگشتی را در قیمت ها مشخص می کنند.
- مدل های تک مسیره (fBm و واسیچک) به دلیل عدم پوشش کامل ویژگی های آماری بازار، عملکرد ضعیفی دارند.
- مدل های MLP و PSO عملکردی متوسط و نسبت به مدل GA ناپایدارتر هستند.
- مدل GA نسبت به تغییرات پارامترهای کلیدی H ، σ ، k و ضرایب ترکیبی مقاوم و پایدار است.

این نتایج تأکید می کنند که ترکیب مسیرهای پایه با الگوریتم بهینه سازی ژنتیک، نه تنها موجب کاهش خطای پیش بینی می شود، بلکه توانایی مدل در پوشش ریسک و مدیریت رفتار افراطی بازده ها را به طور قابل توجهی بهبود می بخشد و برای بازارهای نوسانی مانند بیت کوین و شاخص های سهام قابل توصیه است.

۶ نتیجه گیری کلی

نتایج حاصل از پیش بینی قیمت بیت کوین و شاخص $S\&P500$ با استفاده از مدل ترکیبی مبتنی بر الگوریتم ژنتیک، نشان دهنده توانمندی قابل توجه این مدل در تحلیل و پیش بینی تحولات این بازارها است. ترکیب مسیرهای شبیه سازی شده مبتنی بر مدل های واسیچک و حرکت براونی کسری و بهینه سازی ضرایب آن ها به کمک الگوریتم ژنتیک، دقت پیش بینی را به شکل چشم گیری افزایش داده و امکان شناخت بهتر رفتار قیمتی و پویایی های بازار بیت کوین و شاخص $S\&P500$ را فراهم آورده است.

جهت اعتبارسنجی مدل، از آزمون های آماری کوپیک و کریستوفرسن استفاده شد که ابزار مناسبی برای بررسی انطباق نرخ شکست مدل و استقلال نقض ها در بازه های زمانی مختلف فراهم کردند. نتایج نشان داد مدل ترکیبی پیشنهادی در هر دو بازار از نظر آماری معتبر بوده و معیارهای پذیرش را در سطوح اطمینان مختلف با موفقیت پشت سر گذاشته است؛ در حالی که مدل های منفرد واسیچک و حرکت براونی کسری موفق به کسب این اعتبار نشدند. مدل های ترکیبی MLP و PSO نیز عملکردی متوسط داشتند و پایداری آن ها نسبت به مدل GA کمتر بود.

مزایای اقتصادی مدل پیشنهادی شامل افزایش دقت پیش بینی مسیر قیمت هر دو بازار، بهبود تصمیم گیری سرمایه گذاران و تسهیل مدیریت ریسک ناشی از نوسانات شدید بازارهای رمزارز و سهام است. پیش بینی قابل اتکا و دقیق بازدهی قیمت، امکان اتخاذ استراتژی های سرمایه گذاری

کارآمدتر و تخصیص بهتر منابع اقتصادی را فراهم می‌آورد. این امر به سرمایه‌گذاران، تحلیل‌گران مالی و نهادهای مدیریت ریسک کمک می‌کند تا ریسک‌های پیش‌بینی‌نشده را کاهش دهند و از مزیت رقابتی بیشتری بهره‌مند شوند.

محدودیت‌های مدل نیز عبارت‌اند از: حساسیت مدل به تغییرات شدید شرایط بازارهای نوظهور، وابستگی به داده‌های تاریخی که ممکن است شوک‌های غیرقابل پیش‌بینی را پوشش ندهد و نیاز به زمان محاسباتی و منابع سخت‌افزاری قابل توجه برای اجرای الگوریتم ژنتیک. بنابراین، استفاده عملی از مدل باید همراه با تحلیل‌های مکمل، پایش مداوم بازار و احتیاط در تصمیم‌گیری باشد.

محدودیت‌های تحقیق: یکی از محدودیت‌های اصلی این پژوهش، ناتوانی مدل‌های کلاسیک در پوشش کامل پدیده‌های ناپیوسته در سری‌های زمانی است؛ به‌طور خاص، مدل حرکت براونی کسری (fBm) قادر به مدل‌سازی کامل پرش‌های ناپیوسته در بازارهایی مانند بیت‌کوین نیست و مدل واسیچک نیز برای این بازارها کارایی لازم را ندارد. لازم به ذکر است که در چارچوب پیشنهادی، از مدل واسیچک صرفاً برای تولید مسیرهای شبیه‌سازی‌شده مکمل در کنار فرآیند براونی کسری استفاده شده است. این مسیرها به‌عنوان ورودی‌های کاندید در یک مدل ترکیبی در نظر گرفته شده و با استفاده از الگوریتم ژنتیک، به‌صورت تطبیقی وزن‌دهی و ترکیب شده‌اند تا مسیر پیش‌بینی نهایی حاصل گردد. بنابراین، مدل واسیچک نه به‌عنوان یک ابزار پیش‌بینی مستقل، بلکه به‌عنوان مولد نوسانات کوتاه‌مدت میانگین‌گرا در چارچوب یک مدل ترکیبی مورد استفاده قرار گرفته است. در کارهای آتی، می‌توان با بهره‌گیری از توزیع‌های مبتنی بر پرش (Jump-Diffusion) و همچنین استفاده از روش‌های یادگیری ماشین به‌عنوان ابزار کمکی برای تقویت مدل‌های فعلی، دقت پیش‌بینی را بهبود بخشید.

در مجموع، مدل ترکیبی مبتنی بر الگوریتم ژنتیک نه تنها موجب ارتقای کیفیت پیش‌بینی‌ها در بازار بیت‌کوین و شاخص $S\&P500$ شده است، بلکه می‌تواند به افزایش کارایی بازارهای مالی و تخصیص بهینه منابع اقتصادی کمک کند. بهره‌گیری از چنین رویکردهایی در شرایط نوسان شدید و عدم قطعیت بازار، مزیت رقابتی قابل توجهی برای فعالان اقتصادی فراهم می‌آورد.

فهرست منابع

- [۱] جعفری، منصوری خواه and پورآقاجان، ۲۰۲۳. پیش‌بینی بازده سهام با تاکید بر نقش معیارهای مالی و نظارتی با استفاده از روش‌های یادگیری ماشین. مطالعات حسابداری و حسابرسی، ۱۲(۴۵)، ۱۲۵-۱۴۶. (doi : ۱۷۲۶۸۷.۲۰۲۳/iaas.۲۲۰۳۴.۱۰)
- [۲] ابراهیم رحیمی، احمد محمدی، علی اصغر متقی و سیدعلی پایتختی اسکویی، ۲۰۲۵. تجزیه و تحلیل شوک‌های بازار با مدل هیبریدی ARMA-GARCH و یادگیری عمیق برای پیش‌بینی پیشرفته. مدیریت پویا و تحلیل کسب‌وکار، ۳(۵)، ۱۷۸-۱۹۹. (doi : ۱۱۴۶.۲۰۴۳۱۲۵.۲۰۲۴/dmbaj.۲۲۰۳۴.۱۰)
- [۳] حیدری دلویی، وحدتی، محبی و باقرپور، ۲۰۲۵. پیش‌بینی‌پذیری شاخص کل بورس اوراق بهادار تهران با رویکرد یادگیری ماشین ترکیبی: تحلیل کارایی بازار و اهمیت متغیرهای مؤثر. تحقیقات مالی. (doi : ۱۰۰۷۷۳۸.۳۹۴۷۴۷.۲۰۲۵/frj.۲۲۰۵۹.۱۰)
- [4] Talaie Kakolaki L., Madanchi M., Torabi T., Ghaffari F. (2024). 'Developing a model for predicting the Tehran Stock Exchange index using a combination of artificial neural network and Markov hidden model', *Journal of Investment Knowledge*, 13(50), pp. 135-157.
- [5] Alexander, C., 2001. *Market Models: A Guide to Financial Data Analysis*. University of Sussex.
- [6] Diebold, F.X. and Mariano, R.S., 1995. Comparing predictive accuracy. *Journal of Business and Economic Statistics*, 13(3), pp.253-263. (doi: 10.1198/073500102753410444)
- [7] Goldberg, D., 1989. *Genetic Algorithms in Search, Optimization, and Machine Learning*. MA: Addison-Wesley.
- [8] Ho, M.K., Darman, H. and Musa, S., 2021, July. Stock price prediction using ARIMA, neural network and LSTM models. In *Journal of Physics: Conference Series*, 1988(1), p. 012041. (doi: 10.1088/1742-6596/1988/1/012041)
- [9] Mahdi, E., Martin-Barreiro C. and Cabezas X., 2025. A Novel Hybrid Approach Using an Attention-Based Transformer and GRU Model for Predicting Cryptocurrency Prices. *Mathematics*, 13(9), p. 1484. (doi: 10.3390/math13091484)

- [10] Nagula, P.K. and Alexakis, C., 2022. A new hybrid machine learning model for predicting the bitcoin (BTC-USD) price. *Journal of Behavioral and Experimental Finance*, 36, p.100741. (doi: 10.1016/j.jbef.2022.100741)
- [11] Kupiec, P.H., 1996. Evaluation of porcelain surface treatments and agents for composite-to-porcelain repair. *The Journal of Prosthetic Dentistry*, 76(2), pp.119-124. (doi: 10.1016/S0022-3913(96)90294-2)
- [12] Eberhart, R. and Kennedy, J., 1995. Particle swarm optimization. *Proceedings of the IEEE International Conference on Neural Networks*, 4, pp. 1942-1948. (doi: 10.1109/ICNN.1995.488968)
- [13] Haykin, S., 1994. Neural networks: a comprehensive foundation. Prentice Hall PTR.
- [14] Leventides, J., Melas, E., Poullos, C., Livada, M., Poullos, N.C. and Boufounou, P., 2024. Application of the fractal Brownian motion to the Athens stock exchange. *Fractal and Fractional*, 8(8), p.454. (doi: 10.3390/fractalfract8080454)
- [15] Mandelbrot, B.B. and Van Ness, J.W., 1968. Fractional Brownian motions, fractional noises and applications. *SIAM Review*, 10(4), pp. 422-437. (doi: 10.1137/1010093)
- [16] Nadarajan, S. and Nur-Firyal, R., 2024. Comparing vasicek model with ARIMA and GBM in forecasting Bursa Malaysia stock prices. *AIP Conference Proceedings*, 2905(1), p. 050004. (doi: 10.1063/5.0171662)
- [17] Ofomata, A., Inyama, S., Umana, R. and Oname, A., 2018. A stochastic model of the dynamics of stock price for forecasting. *Journal of Advances in Mathematics and Computer Science*, 25(6), pp. 1-24.
- [18] Peters, E.E., 1994. *Fractal market analysis: Applying chaos theory to investment and economics*. John Wiley & Sons.
- [19] Vasicek, O., 1977. An equilibrium characterization of the term structure. *Journal of Financial Economics*, 5(2), pp. 177-188. (doi: 10.1016/0304-405X(77)90016-2)
- [20] Fergusson, K. and Platen, E., 2015. Application of maximum likelihood estimation to stochastic short rate models. *Annals of Financial Economics*, 10(02), p. 1550009. (doi: 10.1142/S2010495215500098)
- [21] Wipplinger, E., 2007. Philippe Jorion: Value at Risk—the new benchmark for managing financial risk. *Financial Markets and Portfolio Management*, 21(3), p. 397. (doi: 10.1007/s11408-007-0057-3)
- [22] Gerebrink, A., Lundgren, J., Malmström, F., and Thorén, O., 2019. Maximum likelihood calibration of the Vasicek model to the Swedish interest rate market.



Prediction of Asset Prices Using the Fractional Brownian Motion Process and the Vasicek Model Based on a Genetic Algorithm

Ali Khani^{(1)*}, Eskandar Besham⁽¹⁾, Davood Ahmadian⁽²⁾

⁽¹⁾ Department of Mathematics, Azarbaijan Shahid Madani University, Tabriz, Iran

⁽²⁾ Department of Applied Mathematics, University of Tabriz, Tabriz, Iran

Communicated by: Mansour Seraj

Received: 14 July 2025

Accepted: 9 June 2026

Abstract: Precise modeling of asset price trajectories in turbulent financial markets, especially cryptocurrencies, has always faced challenges such as complex temporal dependencies and nonlinear behavior. Classical models, such as Brownian motion, have limitations in simulating features like long memory and mean reversion. In this study, by combining the fractional Brownian motion process and the Vasicek model, and utilizing a genetic algorithm for optimizing the combination weights, a novel framework for asset price path simulation is presented. In this approach, the aforementioned models are implemented separately based on historical data, and their results are combined using optimal weighting coefficients. Then, by defining an objective function based on minimizing the prediction error, the optimal weights are calculated using the genetic algorithm. The findings, based on Bitcoin data, indicate that the proposed hybrid model demonstrates greater accuracy compared to individual models and offers acceptable performance in forecasting price fluctuations. This framework can serve as an efficient tool in financial decision-making, risk management, and the design of investment strategies in highly volatile markets.

Keywords: Fractional Brownian motion, Vasicek model, genetic algorithm, asset price path optimization.



©2024 Shahid Chamran University of Ahvaz, Ahvaz, Iran. This article is an open-access article distributed under the terms and conditions of the Creative Commons Attribution-NonCommercial 4.0 International (CC BY-NC 4.0 license) (<http://creativecommons.org/licenses/by-nc/4.0/>).